

Support Vector Machines (SVM)

Computational Intelligence II

Informatik - Software and Information Engineering
Fachhochschule Vorarlberg

Erstellt von
André Hopfgartner & Matthias Rupp

Dornbirn, am 6. März 2021

Inhaltsverzeichnis

Abkürzungsverzeichnis	3
1 Einführung	4
1.1 Intuition	4
1.2 Mathematische Herleitung	4
1.2.1 Problemdefinition	4
1.2.2 Optimierungsproblem	6
1.2.3 Lagrange Optimierung	6
1.2.4 Quadratic Programming Solver	9

Abkürzungsverzeichnis

SVM Support Vector Machine

1 Einführung

1.1 Intuition

Ziel: möglichst breites Band zwischen den 2 verschiedenen Klassen aufziehen.

1.2 Mathematische Herleitung

TODO TEXT HERE

1.2.1 Problemdefinition

Gegeben sei ein Gewichtsvektor $w \in \mathbb{R}^D$, ein Bias $b \in \mathbb{R}$, ein beliebiger Punkt $x_n \in \mathbb{R}^D$ und ein zugehöriges Label $y_n \in \{1, +1\}$. Eine Ebene im Raum kann allgemein definiert werden durch:

$$w^T x_n + b = 0 \quad (1.1)$$

Weiters soll für eine richtige Klassifikation gelten:

$$w^T x_n + b \geq +1 \quad \text{für } y_k = +1 \quad (1.2a)$$

$$w^T x_n + b \leq -1 \quad \text{für } y_k = -1 \quad (1.2b)$$

Gleichung 1.2 kann weiter verallgemeinert werden durch beidseitige Multiplikation mit y_k :

$$y_k(w^T x_n + b) \geq 1 \quad \text{für } y_k = +1 \quad (1.3a)$$

$$y_k(w^T x_n + b) \geq 1 \quad \text{für } y_k = -1 \quad (1.3b)$$

Für den Grenzfall, dass $x_n = \hat{x}$ genau an der Grenze der Trennebene liegt, gilt somit:

$$y_k(w^T \hat{x} + b) = 1 \quad (1.4)$$

Als nächsten Schritt bestimmen wir den euklidischen Normalabstand D eines beliebigen Punkts $x_n \in \mathbb{R}^D$ zu der Ebene. Hierfür ist zuerst zu bemerken, dass w normal zur definierten Ebene steht.

Lemma 1.2.1. *Eine Ebene sei definiert durch $w^T x + b = 0$. Der Vektor w steht normal zu der definierten Ebene.*

Beweis. Man wähle zwei Punkte $x_1, x_2 \in \mathbb{R}^D$ die auf der Ebene liegen. Somit muss gelten:

$$\begin{aligned} w^T x_1 + b &= 0 \\ w^T x_2 + b &= 0 \\ w^T (x_1 - x_2) &= 0 \leftrightarrow \|w^T\| \|x_1 - x_2\| \cos(\alpha) = 0 \leftrightarrow \alpha = 90^\circ \end{aligned} \quad (1.5)$$

□

Um den Normalabstand D eines beliebigen Punkts x_n zu ermitteln wählt man einen Punkt x , der auf der Ebene liegt, und projiziert den Vektor $(x_n - x)$ auf den Einheitsvektor von w . Weil nur der tatsächliche Abstand zur Ebene relevant ist und nicht die Richtung nimmt man den Betrag.

$$\begin{aligned} D &= \left| \frac{w^T}{\|w\|} (x_n - x) \right| = \\ &= \frac{1}{\|w\|} |(w^T x_n - w^T x)| = \\ &= \frac{1}{\|w\|} |(w^T x_n + b - (w^T x + b))| \end{aligned} \quad (1.6)$$




Abbildung 1.1: Durch die Projektion von $(x_n - x)$ auf den Einheitsvektor von w kann der Normalabstand D von x_n zu der Ebene bestimmt werden.

Weil der Punkt x auf der Ebene liegt gilt $w^T x + b = 0$ (Gleichung 1.1):

$$D = \frac{1}{\|w\|} |(w^T x_n + b)| \quad (1.7)$$

Nun trifft man die Annahme, dass $x_n = \hat{x}$ der am nächsten zu der Trenngrenze liegende Punkt ist. Aus Gleichung 1.4 gilt $y_k(w^T \hat{x} + b) = 1 = |w^T \hat{x} + b|$ unter der Annahme, dass der Punkt richtig klassifiziert wurde. Somit ergibt sich der kleinste Abstand zur Trennebene als:

$$D = \frac{1}{\|w\|} \quad (1.8)$$

1.2.2 Optimierungsproblem

Gleichung 1.8 beschreibt den Normalabstand zu dem am nächsten an der Ebene liegenden Punkt \hat{x} . Ziel einer Support Vector Machine (SVM) ist die Maximierung dieses Abstands für N Eingabevektoren $\{x_1 \dots x_N\}$, $x_n \in \mathbb{R}^D$. Hierbei handelt es sich um ein Optimierungsproblem mit Nebenbedingungen:

$$\max_w \quad \frac{1}{\|w\|} \quad (1.9a)$$

$$\text{mit} \quad \min_{n=1..N} |w^T x_n + b| = 1 \quad (1.9b)$$

Gleichung 1.9b beschreibt hier den am nächsten zur Ebene gelegenen Punkt \hat{x} aus der gegebenen Menge von Eingabevektoren in allgemeiner Form. Der Betrag lässt sich umschreiben durch die Anwendung von Gleichung 1.3:

$$|w^T x_n + b| = y_n(w^T x_n + b) \quad (1.10)$$

Durch Anwendung von Gleichung 1.10 in Gleichung 1.9b, Umformulierung der Maximierung in eine Minimierung und der Verallgemeinerung von \hat{x} auf beliebige Punkte x_n erhält man:

$$\min_w \quad \frac{1}{2} w^T w \quad (1.11a)$$

$$\text{mit} \quad y_n(w^T x_n + b) \geq 1 \text{ für } n = 1..N \quad (1.11b)$$

Die Verallgemeinerung von Gleichung 1.9b auf Gleichung 1.11b auf beliebige Punkte ist so möglich, weil durch Gleichung 1.4 sichergestellt ist, dass für beliebige Punkte $y_n(w^T x_n + b) \geq 1$ gilt.

1.2.3 Lagrange Optimierung

Das beschriebene Optimierungsproblem beinhaltet eine Ungleichung in Gleichung 1.11b. Diese Optimierung kann mittels des Karush–Kuhn–Tucker Ansatzes gelöst werden.

Zuerst wird die Nebenbedingung umgeformt:

$$\min_w \quad \frac{1}{2} w^T w \quad (1.12a)$$

$$\text{mit} \quad y_n(w^T x_n + b) - 1 \geq 0 \text{ für } n = 1..N \quad (1.12b)$$

$y_n(w^T x_n + b) - 1$ kann hierbei als eine Art Schlupf verstanden werden. Das Problem kann nun formuliert werden:

$$\min_{w,b} \quad \mathcal{L}(w, b, \alpha) = \frac{1}{2} w^T w - \sum_{n=1}^N \alpha_n (y_n(w^T x_n + b) - 1) \quad (1.13a)$$

$$\max_{\alpha_n} \quad \alpha_n \geq 0 \text{ für } n = 1..N \quad (1.13b)$$

Nun kann die uneingeschränkte Optimierung von Gleichung 1.13a nach w und b gelöst werden indem die Ableitungen bestimmt und 0 gesetzt werden.

$$\nabla_w \mathcal{L} = w - \sum_{n=1}^N \alpha_n y_n x_n \stackrel{!}{=} \vec{0} \quad (1.14)$$

$$w = \sum_{n=1}^N \alpha_n y_n x_n$$

$$\frac{\partial}{\partial b} \mathcal{L} = - \sum_{n=1}^N \alpha_n y_n \stackrel{!}{=} 0 \quad (1.15)$$

$$\sum_{n=1}^N \alpha_n y_n = 0$$

Die Ergebnisse von Gleichung 1.14 und Gleichung 1.15 können in Gleichung 1.13a eingesetzt werden.

$$\begin{aligned} \mathcal{L}(w, b, \alpha) &= \frac{1}{2} w^T w - \sum_{n=1}^N \alpha_n (y_n(w^T x_n + b) - 1) = \\ &= \frac{1}{2} w^T w - \left[\sum_{n=1}^N \alpha_n y_n b - \sum_{n=1}^N \alpha_n + \sum_{n=1}^N \alpha_n y_n w^T x_n \right] \end{aligned} \quad (1.16)$$

Weil $\sum_{n=1}^N \alpha_n y_n = 0$ aus Gleichung 1.15 fällt der Term $\sum_{n=1}^N \alpha_n y_n b$ weg:

$$\mathcal{L}(w, b, \alpha) = \frac{1}{2} w^T w - \left[- \sum_{n=1}^N \alpha_n + \sum_{n=1}^N \alpha_n y_n w^T x_n \right] \quad (1.17)$$

Vergleicht man den Term $\sum_{n=1}^N \alpha_n y_n w^T x_n$ mit dem Ergebnis von Gleichung 1.14 erkennt man, dass $\sum_{n=1}^N \alpha_n y_n w^T x_n = w^T w$ gilt. Dies kann ausgeschrieben werden

als:

$$\mathcal{L}(\alpha) = \sum_{n=1}^N -\frac{1}{2} \sum_{n=1}^N \sum_{m=1}^M y_n y_m \alpha_n \alpha_m x_n^T x_m \quad (1.18)$$

Gleichung 1.18 beschreibt das Optimierungsproblem ohne Abhängigkeit von w und b , wir haben jetzt also eine Maximierung für α mit Nebenbedingungen:

$$\max_{\alpha} \quad \mathcal{L}(\alpha) = \sum_{n=1}^N -\frac{1}{2} \sum_{n=1}^N \sum_{m=1}^M y_n y_m \alpha_n \alpha_m x_n^T x_m \quad (1.19a)$$

$$\text{mit} \quad \alpha_n \geq 0 \text{ für } n = 1..N \quad (1.19b)$$

$$\sum_{n=1}^N \alpha_n y_n = 0 \text{ für } n = 1..N \quad (1.19c)$$

Das in Gleichung 1.19 beschriebene Problem kann beispielsweise mittels eines Quadratic Programming Solvers gelöst werden. Als Ergebnis erhält man einen Vektor α mit allen α_n . Durch Einsetzen in $w = \sum_{n=1}^N \alpha_n y_n x_n$ kann w bestimmt werden.

Betrachtet man den Ergebnisvektor α wird man feststellen, dass sehr viele Werte 0 ergeben. In Gleichung 1.13a befindet sich der Term $\alpha_n(y_n(w^T x_n + b) - 1)$ und $(y_n(w^T x_n + b) - 1)$ wurde bereits zuvor als Schlupf bezeichnet. Das Produkt von Schlupf und α_n kann nur 0 werden, wenn entweder der Schlupf 0 ist oder α_n . Umgekehrt bedeutet dies, dass alle Vektoren, die einen minimalen Abstand zu der Trennebene haben, ein $\alpha_n \neq 0$ haben. Diese Vektoren werden Stützvektoren genannt.

Mit dieser Erkenntnis kann Gleichung 1.14 erneut analysiert werden:

$$w = \sum_{n=1}^N \alpha_n y_n x_n \quad (1.20)$$

Weil nur Stützvektoren ein $\alpha_n \neq 0$ aufweisen und somit auch nur Stützvektoren einen Beitrag zu w leisten kann Gleichung 1.20 stark vereinfacht werden:

$$w = \sum_{n \text{ ist Stützvektor}} \alpha_n y_n x_n \quad (1.21)$$

Der Gewichtsvektor w hängt also lediglich von einigen, in der Regeln wenigen, Stützvektoren ab.

Noch offen ist die Bestimmung des Bias b . Weil für Stützvektoren $y_n(w^T x_n + b) = 1$ gilt (Gleichung 1.4) kann der Bias b aus jedem beliebigen Stützvektor bestimmt werden:

$$b = \frac{1}{y_n} - w^T x_n \quad (1.22)$$

1.2.4 Quadratic Programming Solver

TODO