FH Vorarlberg
University of Applied Sciences

Support Vector Machines (SVM)

Computational Intelligence II

Informatik - Software and Information Engineering
Fachhochschule Vorarlberg

Erstellt von
André Hopfgartner & Matthias Rupp

Dornbirn, am 6. März 2021

Inhaltsverzeichnis

Abkürzungsverzeichnis

SVM Support Vector Machine

1 Einführung

1.1 Intuition

Ziel: möglichst breites Band zwischen den 2 verschiedenen Klassen aufziehen.

1.2 Mathematische Herleitung

TODO TEXT HERE

1.2.1 Problemdefinition

Gegeben sei ein Gewichtsvektor $w \in \mathbb{R}^D$, ein Bias $b \in \mathbb{R}$, ein beliebiger Punkt $x_k \in \mathbb{R}^D$ und ein zugehöriges Label $y_k \in \{1, +1\}$. Eine Ebene im Raum kann allgemein definiert werden durch:

$$w^T x_k + b = 0 \tag{1.1}$$

Weiters soll für eine richtige Klassifikation gelten:

$$w^T x_k + b \geq +1 \qquad \text{für } y_k = +1 \tag{1.2a}$$
$$w^T x_k + b \leq -1 \qquad \text{für } y_k = -1 \tag{1.2b}$$

Gleichung 1.2 kann weiter verallgemeinert werden durch beidseitige Multiplikation mit y_k:

$$y_k(w^T x_k + b) \geq 1 \qquad \text{für } y_k = +1 \tag{1.3a}$$
$$y_k(w^T x_k + b) \geq 1 \qquad \text{für } y_k = -1 \tag{1.3b}$$

Für den Grenzfall, dass $x_k = \hat{x}$ genau an der Grenze der Trennebene liegt, gilt somit:

$$y_k(w^T \hat{x} + b) = 1 \tag{1.4}$$

Als nächsten Schritt bestimmen wir den euklidischen Normalabstand D eines beliebigen Punkts $x_k \in \mathbb{R}^D$ zu der Ebene. Hierfür ist zuerst zu bemerken, dass w normal zur definierten Ebene steht.

Lemma 1.2.1. *Eine Ebene sei definiert durch $w^T x + b = 0$. Der Vektor w steht normal zu der definierten Ebene.*

Beweis. Man wähle zwei Punkte $x_1, x_2 \in \mathbb{R}^D$ die auf der Ebene liegen. Somit muss gelten:

$$\begin{aligned} w^T x_1 + b &= 0 \\ w^T x_2 + b &= 0 \\ w^T(x_1 - x_2) = 0 \leftrightarrow \|w^T\|\|x_1 - x_2\| \cos(\alpha) &= 0 \leftrightarrow \alpha = 90° \end{aligned} \tag{1.5}$$

□

Um den Normalabstand D eines beliebigen Punkts x_k zu ermitteln wählt man einen Punkt x, der auf der Ebene liegt, und projiziert den Vektor $(x_k - x)$ auf den Einheitsvektor von w. Weil nur der tatsächliche Abstand zur Ebene relevant ist und nicht die Richtung nimmt man den Betrag.

$$\begin{aligned} D &= |\frac{w^T}{\|w\|}(x_k - x)| = \\ &= \frac{1}{\|w\|}|(w^T x_k - w^T x)| = \\ &= \frac{1}{\|w\|}|(w^T x_k + b - (w^T x + b))| \end{aligned} \tag{1.6}$$

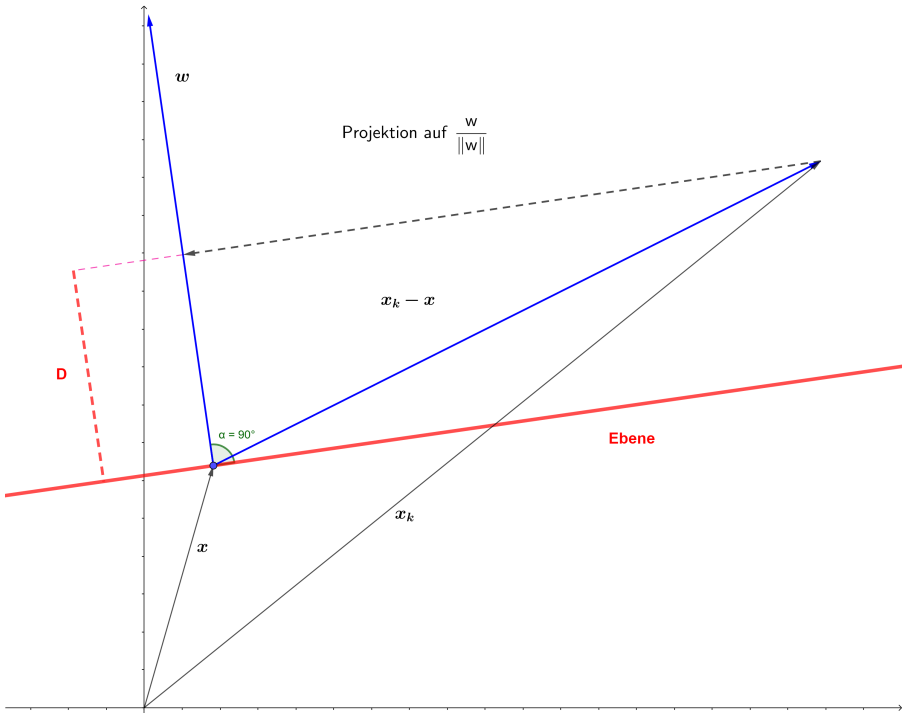

Abbildung 1.1: Durch die Projektion von $(x_k - x)$ auf den Einheitsvektor von w kann der Normalabstand D von x_k zu der Ebene bestimmt werden.

Weil der Punkt x auf der Ebene liegt gilt $w^T x + b = 0$ (Gleichung 1.1):

$$D = \frac{1}{\|w\|}|(w^T x_k + b)| \tag{1.7}$$

Nun trifft man die Annahme, dass $x_k = \hat{x}$ der am nächsten zu der Trenngrenze liegende Punkt ist. Aus Gleichung 1.4 gilt $y_k(w^T \hat{x} + b) = 1 = |w^T \hat{x} + b|$ unter der Annahme, dass der Punkt richtig klassifiziert wurde. Somit ergibt sich der kleinste Abstand zur Trennebene als:

$$D = \frac{1}{\|w\|} \tag{1.8}$$

1.2.2 Optimierungsproblem

Gleichung 1.8 beschreibt den Normalabstand zu dem am nächsten an der Ebene liegenden Punkt $\hat{x_k}$. Ziel einer Support Vector Machine (SVM) ist die Maximierung dieses Abstands für alle N Eingabevektoren $\{x_1..x_N\}, x_n \in \mathbb{R}^D$. Hierbei handelt es sich um ein Optimierungsproblem mit Nebenbedingungen:

$$\max_w \quad \frac{1}{\|w\|} \tag{1.9a}$$

$$\text{mit} \quad \min_{n=1..N} |w^T x_n + b| = 1 \tag{1.9b}$$

Gleichung 1.9b beschreibt hier den am nächsten zur Ebene gelegenen Punkt $\hat{x}$ in allgemeiner Form. Der Betrag lässt sich umschreiben durch die Multiplikation mit dem zugehörigen Label y_n. Für eine korrekte Klassifizierung der SVM gilt:

$$y_n = sign(w^T x_n + b) \tag{1.10}$$

Somit gilt für einen korrekt klassifizierten Vektor x_n:

$$|w^T x_n + b| = y_n(w^T x_n + b) \tag{1.11}$$

Durch Anwendung von Gleichung 1.11 in Gleichung 1.9b, Umformulierung der Maximierung in eine Minimierung und der Verallgemeinerung von $\hat{x}$ auf beliebige Punkte x_n erhält man:

$$\min_w \quad \frac{1}{2} w^T w \tag{1.12a}$$

$$\text{mit} \quad y_n(w^T x_n + b) \geq 1 \text{ für } n = 1..N \tag{1.12b}$$

Die Verallgemeinerung von Gleichung 1.9b auf Gleichung 1.12b auf beliebige Punkte ist so möglich, weil durch Gleichung 1.4 sichergestellt ist, dass der kleinste Wert für $(w^T x_n + b)$ 1 ist, und somit die Werte für alle anderen Punkte größer oder gleich 1 sein müssen.

1.2.3 Lagrange Optimierung

Das beschriebene Optimierungsproblem beinhaltet eine Ungleichung in Gleichung 1.12b. Diese Optimierung kann mittels des Karush–Kuhn–Tucker Ansatzes gelöst werden. Zuerst wird die Nebenbedingung umgeformt:

$$\min_{w} \quad \frac{1}{2} w^T w \tag{1.13a}$$

$$\text{mit} \quad y_n(w^T x_n + b) - 1 \geq 0 \text{ für } n = 1..N \tag{1.13b}$$

$y_n(w^T x_n + b) - 1$ kann hierbei als eine Art Schlupf verstanden werden. Das Problem kann nun formuliert werden:

$$\min_{w,b} \quad \mathcal{L}(w, b, \alpha) = \frac{1}{2} w^T w - \sum_{n=1}^{N} \alpha_n (y_n(w^T x_n + b) - 1) \tag{1.14a}$$

$$\max_{\alpha_n} \quad \alpha_n \geq 0 \text{ für } n = 1..N \tag{1.14b}$$

Nun kann die uneingeschränkte Optimierung von Gleichung 1.14a nach w und b gelöst werden indem die Ableitungen bestimmt und 0 gesetzt werden.

$$\begin{aligned} \nabla_w \mathcal{L} &= w - \sum_{n=1}^{N} \alpha_n y_n x_n \stackrel{!}{=} \vec{0} \\ w &= \sum_{n=1}^{N} \alpha_n y_n x_n \end{aligned} \tag{1.15}$$

$$\begin{aligned} \frac{\partial}{\partial b} \mathcal{L} &= -\sum_{n=1}^{N} \alpha_n y_n \stackrel{!}{=} 0 \\ \sum_{n=1}^{N} \alpha_n y_n &= 0 \end{aligned} \tag{1.16}$$

Die Ergebnisse von Gleichung 1.15 und Gleichung 1.16 können in Gleichung 1.14a eingesetzt werden.

$$\begin{aligned} \mathcal{L}(w, b, \alpha) &= \frac{1}{2} w^T w - \sum_{n=1}^{N} \alpha_n (y_n(w^T x_n + b) - 1) = \\ &= \frac{1}{2} w^T w - [\sum_{n=1}^{N} \alpha_n y_n b - \sum_{n=1}^{N} \alpha_n + \sum_{n=1}^{N} \alpha_n y_n w^T x_n] \end{aligned} \tag{1.17}$$

Weil $\sum_{n=1}^{N} \alpha_n y_n = 0$ aus Gleichung 1.16 fällt der Term $\sum_{n=1}^{N} \alpha_n y_n b$ weg:

$$\mathcal{L}(w, b, \alpha) = \frac{1}{2} w^T w - [-\sum_{n=1}^{N} \alpha_n + \sum_{n=1}^{N} \alpha_n y_n w^T x_n] \tag{1.18}$$

Vergleicht man den Term $\sum_{n=1}^{N} \alpha_n y_n w^T x_n$ mit dem Ergebnis von Gleichung 1.15 erkennt man, dass $\sum_{n=1}^{N} \alpha_n y_n w^T x_n = w^T w$ gilt. Dies kann ausgeschrieben werden als:

$$\mathcal{L}(\alpha) = \sum_{n=1}^{N} -\frac{1}{2} \sum_{n=1}^{N} \sum_{m=1}^{M} y_n y_m \alpha_n \alpha_m x_n^T x_m \tag{1.19}$$

Gleichung 1.19 beschreibt das Optimierungsproblem ohne Abhängigkeit von w und b, wir haben jetzt also eine Maximierung für α mit Nebenbedingungen:

$$\max_{\alpha} \qquad \mathcal{L}(\alpha) = \sum_{n=1}^{N} -\frac{1}{2} \sum_{n=1}^{N} \sum_{m=1}^{M} y_n y_m \alpha_n \alpha_m x_n^T x_m \tag{1.20a}$$

$$\text{mit} \qquad \alpha_n \geq 0 \text{ für } n = 1..N \tag{1.20b}$$

$$\sum_{n=1}^{N} \alpha_n y_n = 0 \text{ für } n = 1..N \tag{1.20c}$$

Das in Gleichung 1.20 beschriebene Problem kann beispielsweise mittels eines Quadratic Programming Solvers gelöst werden. Als Ergebnis erhält man einen Vektor α mit allen α_n. Durch Einsetzen in $w = \sum_{n=1}^{N} \alpha_n y_n x_n$ kann w bestimmt werden.

Betrachtet man den Ergebnisvektor α wird man feststellen, dass sehr viele Werte 0 ergeben. In Gleichung 1.14a befindet sich der Term $\alpha_n(y_n(w^T x_n + b) - 1)$ und $(y_n(w^T x_n + b) - 1)$ wurde bereits zuvor als Schlupf bezeichnet. Das Produkt von Schlupf und α_n kann nur 0 werden, wenn entweder der Schlupf 0 ist oder α_n. Umgekehrt bedeutet dies, dass alle Vektoren, die einen minimalen Abstand zu der Trennebene haben, ein $\alpha_n \neq 0$ haben. Diese Vektoren werden Stützvektoren genannt.

Mit dieser Erkenntnis kann Gleichung 1.15 erneut analysiert werden:

$$w = \sum_{n=1}^{N} \alpha_n y_n x_n \tag{1.21}$$

Weil nur Stützvektoren ein $\alpha_n \neq 0$ aufweisen und somit auch nur Stützvektoren einen Beitrag zu w leisten kann Gleichung 1.21 stark vereinfacht werden:

$$w = \sum_{n \text{ ist Stützvektor}} \alpha_n y_n x_n \tag{1.22}$$

Der Gewichtsvektor w hängt also lediglich von einigen, in der Regeln wenigen, Stützvektoren ab.

Noch offen ist die Bestimmung des Bias b. Weil für Stützvektoren $y_n(w^T x_n + b) = 1$ gilt (Gleichung 1.4) kann der Bias b aus jedem beliebigen Stützvektor bestimmt werden:

$$b = \frac{1}{y_n} - w^T x_n \tag{1.23}$$

1.2.4 Quadratic Programming Solver

TODO